

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

MATHEUS FERREIRA ALPHONSE DOS ANJOS

**ANÁLISE ESTATÍSTICA E QUANTITATIVA DO FATOR CASA NA
PREMIER LEAGUE NA ERA MODERNA**

CORNÉLIO PROCÓPIO

2026

MATHEUS FERREIRA ALPHONSE DOS ANJOS

**ANÁLISE ESTATÍSTICA E QUANTITATIVA DO FATOR CASA NA
PREMIER LEAGUE NA ERA MODERNA**

**Statistical and Quantitative Analysis of the Home Advantage in the Premier
League in the Modern Era**

Proposta de Trabalho de Conclusão de Curso de Graduação apresentada como requisito para obtenção do título de Bacharel em Engenharia da Computação do Bacharelado em Engenharia da Computação da Universidade Tecnológica Federal do Paraná.

Orientador(a): Prof. Ms. Francisco Pereira Junior

CORNÉLIO PROCÓPIO

2026



4.0 Internacional

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

RESUMO

O fenômeno do Fator Casa (*Home Advantage*) representa um dos pilares mais tradicionais da cultura e da dinâmica competitiva do futebol mundial (Courneya; Carron, 1992; Nevill; Holder, 1999). No entanto, as transformações táticas, logísticas e tecnológicas da era moderna levantam questionamentos sobre a real magnitude desse domínio na atualidade (Pollard, 2006; Fischer; Hauer, 2021; García-rubio; Ibáñez; Antúñez, 2025). Este trabalho apresenta uma proposta de análise estatística e quantitativa do Fator Casa na *Premier League*, cobrindo um recorte temporal de 11 temporadas completas (2015/2016 a 2025/2026), com um banco de dados composto por 4.149 partidas (FOOTBALL-DATA.CO.UK, 2024; Premier League, 2024). Ancorada nas fases iniciais da metodologia CRISP-DM, a pesquisa faz uso da linguagem Python e das bibliotecas Pandas, Matplotlib e Seaborn para coleta, saneamento e ciência de dados (Wirth; Hipp, 2000; IBM Corporation, 2018; Wikipédia, 2026). Os resultados preliminares e exploratórios revelaram uma assimetria estatística contundente a favor dos mandantes, com uma taxa de vitória de 44,35% para os times da casa contra 32,08% para os visitantes. A significância estatística dessa disparidade foi comprovada analiticamente por meio da aplicação dos testes Qui-Quadrado e *t* de Welch ($p < 0,05$), rejeitando a hipótese de que a diferença decorre do mero acaso e validando o mando de campo como fator determinante de desempenho. O projeto estabelece as bases de dados tratadas que servirão para o desenvolvimento de modelos preditivos de aprendizado de máquina na etapa subsequente do TCC 2.

CRISP-DM

Palavras-chave: fator casa; ciência de dados; premier league; crisp-dm; estatística esportiva.

Pode retirar as citações do resumo.

ABSTRACT

The phenomenon of Home Advantage represents one of the most traditional pillars of football culture and competitive dynamics worldwide (Courneya; Carron, 1992; Nevill; Holder, 1999). However, the tactical, logistical, and technological transformations of the modern era raise questions regarding the actual magnitude of this dominance today (Pollard, 2006; Fischer; Hauer, 2021; García-rubio; Ibáñez; Antúnez, 2025). This study presents a proposal for a statistical and quantitative analysis of the Home Advantage in the Premier League, covering a timeframe of 11 complete seasons (2015/2016 to 2025/2026), with a dataset comprising 4,149 matches (FOOTBALL-DATA.CO.UK, 2024; Premier League, 2024). Anchored in the initial phases of the CRISP-DM methodology, the research utilizes the Python language along with the Pandas, Matplotlib, and Seaborn libraries for data collection, cleansing, and data science (Wirth; Hipp, 2000; IBM Corporation, 2018; Wikipédia, 2026). Preliminary and exploratory results revealed a strong statistical asymmetry in favor of the hosts, with a 44.35% win rate for home teams compared to 32.08% for visitors. The statistical significance of this disparity was analytically proven through the application of Chi-Square and Welch's t-tests ($p < 0.05$), rejecting the hypothesis that the difference occurs by mere chance and validating the home ground as a determining factor of performance. The project establishes the treated databases that will serve for the development of predictive machine learning models in the subsequent stage of TCC 2.

Keywords: home advantage; data science; premier league; crisp-dm; sports statistics.

SUMÁRIO

1	INTRODUÇÃO	5
1.1	Problema de Pesquisa	5
1.2	Justificativa.....	5
1.3	Objetivos.....	6
1.3.1	Objetivo Geral	6
1.3.2	Objetivos Específicos	6
1.4	Organização do Trabalho.....	6
2	FUNDAMENTAÇÃO TEÓRICA	7
2.1	O Fenômeno do Fator Casa (Home Advantage).....	7
2.1.1	O Impacto da Pandemia e os “Jogos Fantasma”	7
2.2	Metodologia CRISP-DM.....	8
3	PROPOSTA METODOLÓGICA	10
3.1	Ambiente de Desenvolvimento e Tecnologias	10
3.2	Coleta e Fonte de Dados (Data Understanding)	10
3.3	Preparação e Engenharia de Dados (Data Preparation).....	10
3.3.1	Criação de Variáveis de Desempenho	11
3.3.2	Isolamento do Período da Pandemia	11
4	CONSIDERAÇÕES FINAIS E CRONOGRAMA.....	12
4.1	Considerações e Resultados Preliminares	12
4.2	Cronograma de Desenvolvimento (Proposta TCC 2).....	13
	REFERÊNCIAS.....	14

1 INTRODUÇÃO

O futebol inglês possui uma das tradições mais ricas e antigas do cenário desportivo mundial. A *Premier League*, na sua configuração moderna de liga independente, foi fundada em 1992 após uma ruptura estratégica com a antiga *Football League First Division* (cuja fundação original remonta a 1888). Esta transição visou não apenas uma profunda modernização comercial e técnica, mas também a consolidação do campeonato como o produto de entretenimento esportivo mais consumido no planeta (Premier League, 2024).

Dentro do contexto competitivo do futebol, o fenômeno conhecido como "Fator Casa" (*Home Advantage*) surge como um dos pilares centrais da cultura do esporte. Tradicionalmente, assume-se que jogar em domínios próprios confere uma vantagem competitiva real às equipes mandantes, impulsionada por fatores como o apoio de torcidas fervorosas, a familiaridade com o gramado e a pressão psicológica sobre a equipe visitante e a equipe de arbitragem (Courneya; Carron, 1992; Nevill; Holder, 1999).

1.1 Problema de Pesquisa

Embora o Fator Casa seja um conceito amplamente aceito historicamente, o futebol moderno passou por profundas transformações nas últimas décadas. A globalização do esporte, a massificação de esquemas táticos altamente estruturados, a melhoria na logística de viagens e, mais recentemente, a introdução de tecnologias de auxílio à arbitragem (como o VAR) levantaram novos questionamentos. Diante deste cenário de evolução técnica e neutralização de pressões externas, surge o seguinte problema de pesquisa: **Até que ponto o mando de campo ainda se configura como um fator estatisticamente determinante no desempenho das equipes da Premier League na era moderna?**

1.2 Justificativa

A realização deste estudo justifica-se pela necessidade de validar, por meio de uma abordagem estritamente quantitativa e empírica, mitos e convenções enraizados na cultura do futebol profissional. Para além do interesse puramente esportivo, a análise científica do Fator Casa possui relevância prática direta para analistas de desempenho, comissões técnicas (no planejamento estratégico de jogos fora de casa) e para o mercado de ciência de dados aplicada ao esporte. Adicionalmente, o período recente oferece uma oportunidade única de estudo científico: as restrições causadas pela pandemia da COVID-19 forçaram a realização de partidas com portões fechados, criando um cenário de laboratório ideal para isolar o impacto do público nos resultados esportivos, fenômeno este frequentemente denominado na literatura como "jogos fantasma" (Fischer; Hauer, 2021).

1.3 Objetivos

Nesta seção, são delimitados o objetivo geral e os objetivos específicos que guiam a execução desta pesquisa.

1.3.1 Objetivo Geral

Analisar de forma quantitativa e estatística a influência do mando de campo nos resultados e nas métricas de desempenho das equipes na *Premier League*, cobrindo o recorte temporal das temporadas de 2015/16 até a temporada de 2025/26.

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, o trabalho propõe-se a responder às seguintes perguntas de pesquisa:

1. **Magnitude do Domínio:** determinar a porcentagem média de pontos conquistados em casa em comparação com os pontos obtidos fora de casa ao longo das últimas 11 temporadas;
2. **Métricas de Superioridade:** verificar se existe uma correlação direta entre o fato de jogar em casa e o aumento no volume de ações ofensivas, especificamente finalizações (chutes a gol) e escanteios;
3. **Evolução Temporal:** identificar se o Fator Casa apresenta uma tendência de queda, subida ou estabilidade ao longo do período estudado;
4. **Anomalia da Pandemia:** isolar e analisar o impacto da ausência de público (jogos com portões fechados) nas temporadas afetadas pela COVID-19, avaliando como a falta de torcedores alterou a vantagem estatística dos mandantes.

1.4 Organização do Trabalho

Este trabalho está estruturado em quatro capítulos. Este primeiro capítulo apresentou a introdução, o problema de pesquisa, a justificativa e os objetivos do estudo. O Capítulo 2 aborda a Fundamentação Teórica, trazendo o levantamento da literatura sobre o Fator Casa e os conceitos da metodologia CRISP-DM. O Capítulo 3 detalha a Proposta Metodológica, descrevendo a coleta de dados, as tecnologias utilizadas e as técnicas de engenharia de dados aplicadas. Por fim, o Capítulo 4 apresenta as Considerações Finais e o Cronograma de Desenvolvimento proposto para a continuidade e conclusão da pesquisa no TCC 2.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta a base teórica necessária para a compreensão dos conceitos discutidos ao longo do trabalho. Inicialmente, aborda-se o fenômeno do Fator Casa no contexto esportivo e suas variáveis determinantes. Em seguida, detalha-se a metodologia CRISP-DM, utilizada como guia estrutural para o desenvolvimento desta pesquisa em ciência de dados.

2.1 O Fenômeno do Fator Casa (Home Advantage)

O conceito de “Fator Casa” (*Home Advantage*) é amplamente documentado na literatura da ciência do esporte e refere-se à vantagem estatística consistente que os times mandantes possuem sobre os visitantes. Segundo estudos clássicos estruturados por Courneya e Carron (1992) e Pollard (2006), essa vantagem pode ser quantificada pela porcentagem de vitórias ou pontos conquistados em casa, que historicamente supera a marca de 50% em diversas modalidades de esportes coletivos.

Nevill e Holder (1999) realizaram uma ampla revisão da literatura e apontaram que o Fator Casa é um fenômeno multifatorial. As principais variáveis que sustentam esse comportamento incluem:

- **Apoio da Torcida:** ^a A presença do público local atua como um forte motivador psicológico para os jogadores mandantes, além de criar um ambiente de pressão sobre os adversários. ;
- **Familiaridade com o Ambiente:** ^o O conhecimento detalhado das dimensões do campo, das condições do gramado e até mesmo do clima local confere uma vantagem tática sutil, mas real. ;
- **Logística e Cansaço de Viagem:** ^{equipes} Equipes visitantes enfrentam o desgaste físico e mental decorrente de deslocamentos, alterações de rotina e hospedagens, fatores que podem impactar o rendimento atlético. ;
- **Viés de Arbitragem:** Estudos apontam que a pressão exercida pela torcida local pode influenciar, de forma subconsciente, as decisões da equipe de arbitragem em lances cruciais (como cartões e penalidades).

2.1.1 O Impacto da Pandemia e os “Jogos Fantasma”

Um dos momentos mais singulares para o estudo do Fator Casa ocorreu durante a pandemia da COVID-19. As restrições sanitárias forçaram a realização de partidas com portões fechados (conhecidos na Europa como *Ghost Games* ou “Jogos Fantasma”).

Pesquisas recentes, como as de Fischer e Hauer (2021), aproveitaram esse cenário de isolamento para testar empiricamente o peso real da torcida. Isolar essa variável permitiu com-


preender se a vantagem do mandante despencaria sem o público ou se os outros fatores (como a familiaridade com o ambiente de jogo e a viagem) seriam suficientes para garantir a superioridade estatística das equipes da casa.

Complementarmente, investigações sobre o comportamento das ligas europeias nesse período atípico sugerem que a ausência de público afetou diretamente a resiliência dos mandantes, mitigando o efeito tradicional de invencibilidade que historicamente blinda as equipes quando atuam em seus próprios domínios (García-rubio; Ibáñez; Antúnez, 2025).

2.2 Metodologia CRISP-DM

Para a condução de projetos de ciência de dados e mineração de dados (*Data Mining*) de forma sistemática e eficiente, adota-se o modelo *Cross-Industry Standard Process for Data Mining* (CRISP-DM), proposto originalmente por um consórcio industrial de especialistas (IBM Corporation, 2018). O processo é cíclico e composto por seis fases interdependentes:

Figura 1 – Diagrama de Fases do Modelo CRISP-DM.



Fonte: Wikipédia (2026).

Colocar uma outra referência: livro ou artigo

1. **Entendimento do Negócio (*Business Understanding*):** ^{fase} Fase inicial focada em compreender os objetivos do projeto sob a perspectiva de regras de negócio, transformando esse conhecimento em uma definição de problema de ciência de dados. ;
2. **Entendimento dos Dados (*Data Understanding*):** Envolve a coleta inicial dos dados, identificação de problemas de qualidade, primeira exploração das propriedades e descoberta de *insights* preliminares.
3. **Preparação dos Dados (*Data Preparation*):** Fase de tratamento onde os dados brutos são limpos, transformados, filtrados e modelados em conjuntos de dados finais prontos para análise.
4. **Modelagem (*Modeling*):** Seleção e aplicação de diversas técnicas estatísticas e algoritmos de aprendizado de máquina, com o ajuste de seus parâmetros para a otimização dos resultados. Utilizará Aprendizado de Máquina?
5. **Avaliação (*Evaluation*):** Fase de revisão técnica dos resultados obtidos para garantir que as descobertas realmente resolvem o problema de negócio inicial.
6. **Implantação (*Deployment*):** Organização dos resultados em relatórios finais, códigos reaproveitáveis ou *dashboards* para utilização prática.

No escopo deste TCC 1, as etapas de Entendimento do Negócio, Entendimento dos Dados e Preparação foram rigorosamente executadas, permitindo a extração de métricas descritivas sobre a *Premier League*.

3 PROPOSTA METODOLÓGICA

Este capítulo detalha os procedimentos metodológicos adotados para a realização do estudo, cobrindo as fases de coleta, tratamento e preparação dos dados. A estrutura da pesquisa fundamenta-se nas etapas iniciais do modelo CRISP-DM, utilizando ferramentas computacionais especializadas para a manipulação de grandes volumes de dados esportivos.

3.1 Ambiente de Desenvolvimento e Tecnologias

Para garantir a reprodutibilidade da pesquisa e a eficiência no processamento dos dados, o ecossistema de desenvolvimento foi estruturado na linguagem de programação Python 3, utilizando o ambiente de nuvem *Google Colab*. Foram empregadas as seguintes bibliotecas computacionais:

- **Pandas:** Utilizada para a manipulação de estruturas de dados tabulares (*DataFrames*), limpeza de valores nulos e transformações matemáticas.
- **Matplotlib e Seaborn:** Aplicadas na geração de gráficos estatísticos, histogramas e matrizes de correlação para a análise visual.

3.2 Coleta e Fonte de Dados (Data Understanding)

O conjunto de dados utilizado nesta pesquisa foi obtido a partir de repositórios públicos de estatísticas de futebol, contendo o histórico detalhado de todas as partidas da *Premier League* (FOOTBALL-DATA.CO.UK, 2024). O recorte temporal estabelecido abrange 11 temporadas completas, iniciando na temporada 2015/2016 até a temporada de 2025/2026.

No total, o banco de dados brutos compreende 4.180 partidas catalogadas. Cada registro do conjunto de dados contém variáveis originais cruciais, tais como: identificação dos times (mandante e visitante), gols marcados por cada equipe, total de finalizações de cada lado, chutes no alvo e escanteios cobrados.

3.3 Preparação e Engenharia de Dados (Data Preparation)

Os dados brutos coletados necessitaram de manipulações e transformações estruturais para que fosse possível responder aos objetivos específicos da pesquisa. O processo de engenharia de recursos (*feature engineering*) consistiu na criação de novas variáveis métricas a partir dos dados existentes.

3.3.1 Criação de Variáveis de Desempenho

Para analisar o comportamento das equipes em casa e fora de casa, foram computadas colunas matemáticas no *DataFrame* principal. A escolha dessas métricas fundamenta-se na literatura recente de análise de performance esportiva, a qual aponta que a manutenção da invencibilidade nos domínios do clube e a consolidação de pontuação consistente em casa são os pilares determinantes para a eficiência do fator casa (García-rubio; Ibáñez; Antúnez, 2025). As variáveis criadas foram:

- **Gols Totais da Partida:** Soma dos gols do mandante e do visitante, utilizada para medir a dinamicidade dos jogos.
- **Saldo de Gols do Mandante:** Diferença entre os gols marcados pelo time da casa e os gols sofridos, servindo como indicador direto de dominância.
- **Pontos Conquistados:** Aplicação da regra oficial do esporte, atribuindo 3 pontos para vitória do mandante, 1 ponto em caso de empate e 0 pontos para derrota do mandante (replicando a lógica inversa para o vetor do visitante).

Os times que terminaram a temporada nas primeiras posições possuem o mesmo comportamento considerando o Fator Casa do times que terminaram nas últimas posições.

3.3.2 Isolamento do Período da Pandemia

Para cumprir o objetivo de analisar a anomalia gerada pela COVID-19, foi realizada uma filtragem temporal rigorosa. As partidas ocorridas entre 17 de junho de 2020 e 23 de maio de 2021 foram catalogadas sob uma variável binária indicando a ausência de público (portões fechados), permitindo separar estatisticamente as temporadas "normais" das temporadas afetadas pelas restrições sanitárias.

4 CONSIDERAÇÕES FINAIS E CRONOGRAMA

Este capítulo encerra a proposta de trabalho de conclusão de curso, apresentando uma síntese das análises preliminares obtidas na fase exploratória, as conclusões iniciais a respeito do fenômeno do Fator Casa na *Premier League* e o planejamento estruturado para a continuidade e conclusão da pesquisa no TCC 2.

4.1 Considerações e Resultados Preliminares


A execução das etapas iniciais da metodologia CRISP-DM permitiu extrair um diagnóstico quantitativo robusto sobre o comportamento do mando de campo no futebol inglês moderno. A análise descritiva realizada sobre o conjunto consolidado de 4.180 partidas (abrangendo o intervalo entre as temporadas 2015/2016 e 2025/2026) revelou que o Fator Casa permanece como uma variável de influência ativa.

Os resultados preliminares apontam uma distribuição geral onde as vitórias do time mandante representam **44,35%** do total de jogos avaliados, superando sensivelmente os **32,08%** de vitórias das equipes visitantes e os **23,57%** de empates.

Como pode ser observado na Figura 2, o comportamento histórico das linhas de pontuação evidencia a superioridade constante dos mandantes ao longo dos anos. O gráfico também ilustra de forma nítida o estreitamento inédito entre as duas métricas durante o período das temporadas de 2019/2020 e 2020/2021, decorrente do fenômeno dos portões fechados na pandemia da COVID-19, sugerindo o impacto direto da torcida no Fator Casa.

Resultado interesssante!

Figura 2 – Evolução temporal da média de pontos por jogo (mandantes versus visitantes) na Premier League.



Média de outros dados: chutes, escanteios

Melhorar a figura (colocar cores)

Formatação Fonte:

Ver o comportamento das equipes em cada temporada. Do autor (2026).
Ou grupos, os melhores e os piores times.

Para assegurar que essas diferenças de desempenho não decorrem de flutuações puramente aleatórias da amostragem, foram aplicados métodos de inferência estatística com nível de significância de $\alpha = 0,05$:

- **Teste Qui-Quadrado (χ^2):** O teste rejeitou de forma categórica a hipótese nula de igualdade proporcional de resultados ($p < 0,05$), provando que a assimetria a favor do mandante é estatisticamente sólida.
- **Teste t de Welch (Média de Pontos):** O teste estatístico confirmou que a média de pontos conquistados pelas equipes atuando em seus próprios domínios é significativamente superior à média de pontos obtida fora de casa ($p < 0,05$). Usa quando as variâncias dos dois grupos são diferentes.

Esses achados validam empiricamente as hipóteses levantadas na fase de entendimento do negócio e fornecem a sustentação matemática necessária para o desenvolvimento de modelos preditivos avançados na etapa subsequente do trabalho.

4.2 Cronograma de Desenvolvimento (Proposta TCC 2)

Para a conclusão integral do projeto, as fases remanescentes do modelo CRISP-DM — com ênfase nas etapas de Modelagem, Avaliação e Implantação — serão executadas de acordo com o planejamento detalhado na Tabela 1.

Tabela 1 – Cronograma semanal de atividades proposto para o TCC 2.

Atividades / Etapas (2026)	Agosto				Setembro				Outubro				Novembro				Dezembro			
	S1	S2	S3	S4	S1	S2	S3	S4	S1	S2	S3	S4	S1	S2	S3	S4	S1	S2	S3	S4
Revisão da Preparação dos Dados	X	X																		
Implementação dos Modelos de ML			X	X	X	X	X													
Avaliação e Validação Técnica								X	X	X										
Escrita da Monografia Final											X	X	X	X	X	X				
Preparação para a Defesa																	X	X	X	

A execução deste cronograma assegura o cumprimento integral de todos os critérios de sucesso estabelecidos no plano original do projeto.

REFERÊNCIAS

- COURNEYA, K. S.; CARRON, A. V. The home advantage in sport competitions: A review. **Journal of Sport & Exercise Psychology**, Human Kinetics v. 14, n. 1, p. 13–37, 1992.
- FISCHER, K.; HAUER, R. Playing without spectators: how the covid-19 pandemic modification of the home advantage in professional football. **European Journal of Sport Science**, Wiley Online Library,, 2021.
- FOOTBALL-DATA.CO.UK. **Historical Football Data - England Premier League**, . 2024. Acesso em: Maio de 2024. Disponível em: <http://www.football-data.co.uk/englandm.php>.
- GARCÍA-RUBIO, J.; IBÁÑEZ, S. J.; ANTÚNEZ, A. Home advantage in soccer: being invincible during home matches may be the reason. **Trends in Sport Sciences**, v. 32, n. 4,, 2025. Disponível em: <https://tss.awf.poznan.pl>.
- IBM Corporation. IBM Corporation **IBM SPSS Modeler CRISP-DM Guide**. [S.l.], 2018. Acessado em: 11 jun. 2026. Disponível em: <https://www.ibm.com/docs/en/spss-modeler/SaaS?topic=dm-crisp-help-overview>.
- NEVILL, A. M.; HOLDER, R. L. Home advantage in sport: an overview of studies on the advantage of playing at home. **Sports Medicine**, Springer v. 28, n. 4, p. 221–236, 1999.
- POLLARD, R. Worldwide regional variations in home advantage in association football. **Journal of Sports Sciences**, Taylor & Francis v. 24, n. 3, p. 231–240, 2006.
- Premier League. **This is Premier League: Football, community and economy**, . 2024. Acessado em: 11 jun. 2026. Disponível em: <https://www.premierleague.com/publications>.
- Wikipédia. **Cross Industry Standard Process for Data Mining**, . 2026. Acessado em: 11 jun. 2026. Disponível em: https://pt.wikipedia.org/wiki/Cross_Industry_Standard_Process_for_Data_Mining. [Buscar outra referência](#)
- WIRTH, R.; HIPPEL, H. V. Crisp-dm: Towards a standard process model for data mining. In: PROCEEDINGS OF THE 4TH INTERNATIONAL CONFERENCE ON THE PRACTICAL APPLICATIONS OF KNOWLEDGE DISCOVERY AND DATA MINING. 2000. **Anais [...]** [S.l.: s.n.], 2000. p. 29–39.